

Modélisation statistique

#2.c Géométrie des moindres carrés

Dr. Léo Belzile
HEC Montréal

Rappels d'algèbre linéaire

Si \mathbf{X} est une matrice $n \times p$, l'espace engendré par les colonnes de \mathbf{X} est

$$\mathcal{S}(\mathbf{X}) = \{\mathbf{X}\mathbf{a}, \mathbf{a} \in \mathbb{R}^p\}$$

L'équation du modèle linéaire

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

correspond donc à un élément (inconnu) du sous-espace vectoriel engendré \mathbf{X} plus un aléa.

Moindres carrés ordinaires


Trouver l'élément de $\mathcal{S}(\mathbf{X})$ le plus près (distance minimale) de \mathbf{y} , soit

$$\hat{\boldsymbol{\beta}} = \min_{\boldsymbol{\beta} \in \mathbb{R}^p} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2$$

Intuition: $\varepsilon_1, \dots, \varepsilon_n$ et $\beta_0, \dots, \beta_{p-1}$ sont inconnus, on ne peut les recouvrir (n observations, $n + p$ inconnues).

Géométrie des colonnes

On cherche à trouver la meilleure approximation p -dimensionnelle dans $\mathcal{S}(\mathbf{X})$.



La solution du problème des moindres carrés est la projection de \mathbf{y} sur $\mathcal{S}(\mathbf{X})$, soit $\mathbf{H}\mathbf{y}$, où $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ est la matrice de projection.

Décomposition orthogonale

On écrit

$$\begin{aligned}\mathbf{y} &= \mathbf{H}\mathbf{y} + (\mathbf{I}_n - \mathbf{H})\mathbf{y} \\ &= \mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{e}\end{aligned}$$

Les résidus \mathbf{e} sont orthogonaux aux colonnes de \mathbf{X} et donc aux valeurs ajustées $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$.

✚ Par le théorème de Pythagore, $\|\mathbf{y}\|^2 = \|\hat{\mathbf{y}}\|^2 + \|\mathbf{e}\|^2$.

Si $\mathbf{1}_n \in \mathcal{S}(\mathbf{X})$ (le modèle inclut une ordonnée à l'origine)

✚ La moyenne des résidus \mathbf{e} est nulle.

✚ La régression linéaire de $\hat{\mathbf{y}}$ sur \mathbf{e} a une ordonnée à l'origine et une pente nulle (aucune corrélation linéaire).