# Modélisation statistique

#2.c Géométrie des moindres carrés

Dr. Léo Belzile HEC Montréal

## Rappels d'algèbre linéaire

Si X est une matrice  $n \times p$ , l'espace engendré par les colonnes de X est

$$S(\mathbf{X}) = \{\mathbf{X}a, a \in \mathbb{R}^p\}$$

L'équation du modèle linéaire

$$Y = X\beta + \varepsilon$$

correspond donc à un élément (inconnu) du sous-espace vectoriel engendré **X** plus un aléa.

### Moindres carrés ordinaires

Trouver l'élément de S(X) le plus près (distance minimale) de y, soit


$$\hat{\boldsymbol{\beta}} = \min \| \boldsymbol{y} - \mathbf{X}\boldsymbol{\beta} \|^2$$

$$\boldsymbol{\beta} \in \mathbb{R}^p$$

Intuition:  $\varepsilon_1, ..., \varepsilon_n$  et  $\beta_0, ..., \beta_{p-1}$  sont inconnus, on ne peut les recouvrer (n observations, n+p inconnues).

### Géométrie des colonnes

On cherche à trouver la meilleur approximation p-dimensionnelle dans s(x).



La solution du problème des moindres carrés est la projection de y sur S(X), soit Hy, où  $H = X(X^TX)^{-1}X^T$  est la matrice de projection.

### Décomposition orthogonale

On écrit

$$egin{aligned} oldsymbol{y} &= \mathbf{H} oldsymbol{y} + (\mathbf{I}_n - \mathbf{H}) oldsymbol{y} \ &= \mathbf{X} \widehat{oldsymbol{eta}} + oldsymbol{e} \end{aligned}$$

Les résidus e sont orthogonaux aux colonnes de  $\mathbf{x}$  et donc aux valeurs ajustées  $\hat{y} = \mathbf{x}\hat{\boldsymbol{\beta}}$ .

**→** Par le théorème de Pythagore,  $\|\boldsymbol{y}\|^2 = \|\widehat{\boldsymbol{y}}\|^2 + \|\boldsymbol{e}\|^2$ .

Si  $\mathbf{1}_n \in \mathcal{S}(\mathbf{X})$  (le modèle inclut une ordonnée à l'origine)

- lacktriangle La moyenne des résidus e est nulle.
- La régression linéaire de  $\hat{y}$  sur e a une ordonnée à l'origine et une pente nulle (aucune corrélation linéaire).