

MATH 60604
Modélisation statistique
§ 6d - Ordonnée à l'origine aléatoire

Léo Belzile

HEC Montréal
Département de sciences de la décision

Modèles avec ordonnée à l'origine aléatoire

Le modèle de régression linéaire mixte suivant n'a qu'une seule composante aléatoire (une ordonnée à l'origine par groupe). L'équation de la moyenne est

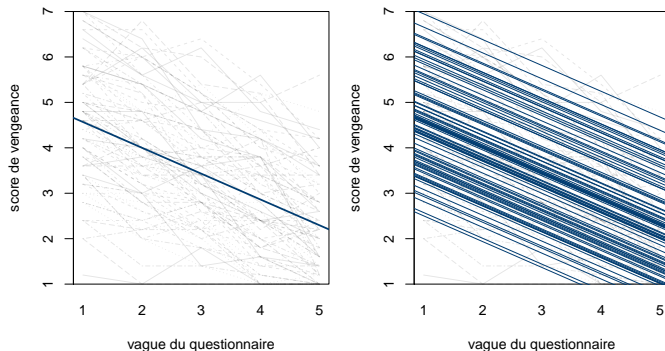
$$Y_{ij} = (\beta_0 + b_i) + \beta_1 X_{ij1} + \cdots + \beta_p X_{ijp} + \varepsilon_{ij}, \quad \varepsilon_i \sim \text{No}(\mathbf{0}, \mathbf{R}_i)$$

pour $i = 1, \dots, m$ et $j = 1, \dots, n_i$ et où Y_{ij} est l'observation j du groupe i . L'**ordonnée à l'origine** du groupe i est désormais $\beta_0 + b_i$. Elle est composée

- d'un effet fixe commun à tous les groupes, β_0 ;
- d'un effet aléatoire spécifique au groupe i , b_i .

Illustration de l'effet aléatoire

On montre l'impact de l'effet aléatoire pour les données vengeance avec covariance $AR(1)$ et t comme variable explicative continue.



Modèle sans effet aléatoire (gauche) et avec effet aléatoire pour id (droite).

Modèle avec ordonnée à l'origine aléatoire

Soit l'équation du modèle,

$$Y_{ij} = (\beta_0 + b_i) + \beta_1 X_{ij1} + \beta_2 X_{ij2} + \cdots + \beta_p X_{ijp} + \varepsilon_{ij}$$

- Les effets aléatoires b_1, \dots, b_m sont supposées indépendants des termes d'aléas ε et des variables explicatives
- On postule pour le moment
 - $b \stackrel{\text{iid}}{\sim} \text{No}(0, \sigma_b^2)$ ($i = 1, \dots, m$).
 - $\varepsilon_{ij} \stackrel{\text{iid}}{\sim} \text{No}(0, \sigma^2)$ ($i = 1, \dots, m; j = 1, \dots, n_i$).

Modèles avec effets aléatoires: covariance

Comme il est aléatoire, le terme b_i introduit de la **corrélation intra-groupe** dans le modèle. Puisque ε_{ij} est indépendant de b_i pour tout i, j , la variance (conditionnelle) d'une observation est

$$\text{Var} (Y_{ij} \mid \mathbf{X}_i) = \text{Var} (b_i) + \text{Var} (\varepsilon_{ij}) = \sigma_b^2 + \sigma^2$$

La covariance entre deux individus d'un même groupe est

$$\text{Cov} (Y_{ij}, Y_{ik} \mid \mathbf{X}_i) = \sigma_b^2, \quad j \neq k.$$

Par conséquent, la corrélation entre deux individus d'un même groupe est

$$\text{Corr} (Y_{ij}, Y_{ik} \mid \mathbf{X}_i) = \frac{\sigma_b^2}{\sigma^2 + \sigma_b^2}, \quad j \neq k.$$

Cette quantité est habituellement appelée **corrélation intra-groupe**.

Aparté mathématique

Les coefficients β_j et les covariables ne sont pas aléatoires, ce qui fait que

$$\begin{aligned}\text{Cov}(Y_{ij}, Y_{ik} \mid \mathbf{X}_i) &= \text{Cov}(\beta_0 + b_i + \beta_1 X_{ij1} + \cdots + \varepsilon_{ij}, \\ &\quad \beta_0 + b_i + \beta_1 X_{ik1} + \cdots + \varepsilon_{ik} \mid \mathbf{X}_i) \\ &= \text{Cov}(b_i + \varepsilon_{ij}, b_i + \varepsilon_{ik}) \\ &= \text{Var}(b_i) + \text{Cov}(\varepsilon_{ij}, \varepsilon_{ik}) \\ &= \sigma_b^2 + \sigma^2 \mathbf{1}_{j=k}.\end{aligned}$$

où la dernière étape vient de l'indépendance entre b_i et ε et puisque $\text{Cov}(Y_{ij}, Y_{ij}) = \text{Var}(Y_{ij})$.

De manière équivalente, on peut écrire

$$\begin{aligned}\text{Var}(\mathbf{Y}_i | \mathbf{X}_i) &= \text{Var}(b_i \mathbf{1}_{n_i}) + \text{Var}(\varepsilon_i) \\ &= \sigma_b^2 \mathbf{1}_{n_i} \mathbf{1}_{n_i}^\top + \sigma^2 \mathbf{I}_{n_i} \\ &= \begin{pmatrix} \sigma_b^2 & \sigma_b^2 & \cdots & \sigma_b^2 \\ \sigma_b^2 & \sigma_b^2 & \cdots & \sigma_b^2 \\ \vdots & \ddots & \ddots & \vdots \\ \sigma_b^2 & \sigma_b^2 & \cdots & \sigma_b^2 \end{pmatrix} + \begin{pmatrix} \sigma^2 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \ddots & 0 \\ \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2 \end{pmatrix}.\end{aligned}$$

Structure d'équicorrélation du modèle avec ordonnée à l'origine aléatoire

- Nous voyons donc que l'introduction d'un effet aléatoire pour l'ordonnée à l'origine fait en sorte que les observations des individus d'un même groupe sont corrélées et que **la corrélation est la même** peu importe les individus choisis (équicorrélation).
- Ainsi, **ajouter un effet aléatoire pour l'ordonnée à l'origine revient à utiliser une structure d'équicorrélation.**

Équicorrélation

- La différence ici est que la corrélation doit nécessairement être plus grande ou égale à zéro sachant que le σ_b^2 est une variance et donc forcément positive, alors que dans le modèle d'équicorrélation, on a

$$-\frac{1}{\max(n_i) + 1} \leq \rho \leq 1.$$

- Ce n'est généralement pas une limitation, car les corrélations intra-groupe ont tendance à être positives.

Ajout d'un effet aléatoire avec la commande `random`

- La commande `repeated` nous permettait de spécifier la structure de covariance des erreurs avec `proc mixed`.
- Si on utilise pas la commande `repeated`, les erreurs sont postulées indépendantes.

Code SAS pour ajuster un modèle avec ordonnée à l'origine aléatoire avec erreurs indépendantes

```
proc mixed data=modstat.mobilisation;  
class idunite;  
model mobilisation = sexe anciennete agegest nunite / solution;  
random intercept / subject=idunite v=1 vcorr=1;  
run;
```

L'inclusion d'une ordonnée à l'origine aléatoire **induit** une structure d'équicorrélation pour les réponses. Il n'est donc pas nécessaire de spécifier une structure de covariance pour les erreurs.

Matrice de covariance du modèle avec ordonnée à l'origine aléatoire

| Matrice V estimée pour idunite 1 | | | | | | | | | |
|----------------------------------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| Ligne | Col1 | Col2 | Col3 | Col4 | Col5 | Col6 | Col7 | Col8 | Col9 |
| 1 | 1.3709 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 |
| 2 | 0.2448 | 1.3709 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 |
| 3 | 0.2448 | 0.2448 | 1.3709 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 |
| 4 | 0.2448 | 0.2448 | 0.2448 | 1.3709 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 |
| 5 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 1.3709 | 0.2448 | 0.2448 | 0.2448 | 0.2448 |
| 6 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 1.3709 | 0.2448 | 0.2448 | 0.2448 |
| 7 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 1.3709 | 0.2448 | 0.2448 |
| 8 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 1.3709 | 0.2448 |
| 9 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 0.2448 | 1.3709 |

Estimés des paramètres de covariance

| Valeur estimée du paramètre de covariance | | |
|---|---------|------------|
| Param. de cov. | Sujet | Estimation |
| Intercept | idunite | 0.2448 |
| Residual | | 1.1261 |

- L'estimé de la variance de l'effet aléatoire est $\hat{\sigma}_b^2 = 0,2448$, tandis que l'estimé de la variance des erreurs est $\hat{\sigma}^2 = 1,1261$.
- Conséquemment, la corrélation intra-unité est

$$\hat{\rho} = \frac{\hat{\sigma}_b^2}{\hat{\sigma}_b^2 + \sigma^2} = 0,1785.$$

- C'est exactement la même corrélation que celle rapportée pour le modèle d'équicorrélation intra-unité des erreurs (commande repeated).

Estimés des effets fixes

| Solution pour effets fixes | | | | | |
|----------------------------|------------|----------------|-----|------------------|---------|
| Effet | Estimation | Erreur type | DDL | Valeur du test t | Pr > t |
| Intercept | 13.7633 | 0.3955 | 97 | 34.80 | <.0001 |
| sexe | 0.5622 | 0.06835 | 914 | 8.23 | <.0001 |
| anciennete | -0.4722 | 0.006015 | 914 | -78.50 | <.0001 |
| agegest | 0.01929 | 0.006801 | 97 | 2.84 | 0.0056 |
| nunite | 0.006470 | 0.02019 | 97 | 0.32 | 0.7493 |

L'effet des variables explicatives (et leurs erreurs-types) sont exactement les même que pour le modèle d'équicorrélation des erreurs — les deux modèles sont équivalents pour la réponse si la corrélation intra-unité est positive.